DETECTION TUMEUR

Joseph Ngouda

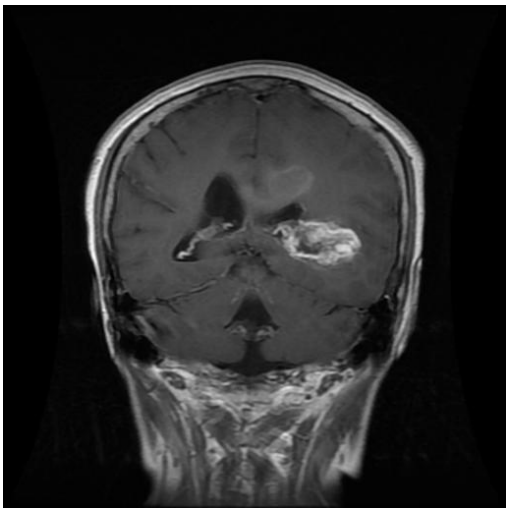

03 FEVRIER 2026

ETUDIANT EN STATISTIQUE ET BIG DATA
Université Aix Marseille

Table des matières

Brain Tumor MRI Dataset 2

Rapport scientifique – Classification d'images IRM cérébrales par Deep Learning 2

1. Abstract 2
2. Introduction 2
3. Description du dataset 3
4. Méthodologie 3
   - 4.1 Prétraitement des données 3
   - 4.2 Architecture du réseau de neurones convolutifs (CNN) 4
   - 4.3 Compilation et entraînement 6
5. Résultats et analyse 6
6. Discussion 7
7. Limites du projet 7
8. Perspectives futures 7

Conclusion 8

Brain Tumor MRI Dataset

Rapport scientifique – Classification d'images IRM cérébrales par Deep Learning

---

1. Abstract

La détection automatique des tumeurs cérébrales à partir d'images d'imagerie par résonance magnétique (IRM) constitue un domaine critique de l'intelligence artificielle appliquée à la médecine. L'objectif de ce projet est de développer un modèle de deep learning capable de réaliser une classification binaire d'images IRM cérébrales en deux catégories : Tumor et No Tumor.

Le dataset utilisé contient 10 093 images réparties entre un ensemble d'entraînement (8 277 images) et un ensemble de test (1 816 images). Les données proviennent d'une combinaison de sources publiques et de collecte indépendante, dans le but d'améliorer la diversité et la robustesse du modèle.

Un réseau de neurones convolutifs (CNN) a été conçu pour apprendre automatiquement les caractéristiques discriminantes des images médicales. Le modèle obtenu atteint une accuracy d'environ 94% sur l'entraînement et 91% sur la validation, indiquant une capacité de généralisation satisfaisante.

Ce travail met en évidence l'efficacité des architectures CNN dans l'analyse d'images médicales et propose une perspective d'évolution vers des approches plus avancées incluant la segmentation et la localisation précise des tumeurs cérébrales.

---

2. Introduction

Les tumeurs cérébrales représentent une pathologie neurologique grave dont le diagnostic précoce est déterminant pour le pronostic du patient. L'imagerie par résonance magnétique (IRM) est aujourd'hui la modalité de référence pour l'analyse des tissus cérébraux en raison de sa haute résolution et de sa capacité à distinguer les structures internes du cerveau.

Cependant, l'interprétation des images IRM repose encore largement sur l'expertise humaine, ce qui introduit plusieurs limitations : variabilité inter-observateur, fatigue cognitive, et temps d'analyse élevé. Ces contraintes justifient le développement de systèmes automatisés capables d'assister les cliniciens.

Le deep learning, et en particulier les réseaux de neurones convolutifs, permet de répondre à cette problématique en apprenant directement des représentations hiérarchiques des données visuelles sans extraction manuelle de caractéristiques.

---

3. Description du dataset

Le dataset utilisé dans ce projet est conçu pour une tâche de classification binaire.

Il est composé de 10 093 images IRM cérébrales réparties comme suit :

- Training set : 8 277 images
- Testing set : 1 816 images

Les images sont organisées en deux classes :

- Tumor
- No Tumor

La classe Tumor provient en partie d'un dataset public fourni par Ayesha Ghaffar (https://data.mendeley.com/datasets/w4sw3s9f59/1), tandis que la classe No Tumor a été collectée indépendamment afin d'améliorer l'équilibre global des données.

L'un des défis majeurs de ce dataset réside dans la variabilité des sources et le risque de déséquilibre entre classes. Un prétraitement et une augmentation de données sont donc nécessaires pour améliorer la capacité de généralisation du modèle.

---

4. Méthodologie

4.1 Prétraitement des données

Les images IRM sont redimensionnées à une taille uniforme de 224×224 pixels afin de garantir une compatibilité avec l'architecture du réseau de neurones. Elles sont ensuite normalisées par division par 255 afin de ramener les valeurs des pixels dans l'intervalle [0,1].

Une augmentation de données est appliquée afin d'améliorer la robustesse du modèle et de réduire le surapprentissage. Cette augmentation inclut des transformations géométriques telles que :

- rotation aléatoire jusqu'à 20 degrés
- zoom aléatoire jusqu'à 20%
- inversion horizontale

Ces transformations permettent de simuler des variations naturelles d'acquisition des IRM et d'éviter que le modèle n'apprenne des caractéristiques spécifiques non généralisables.

4.2 Architecture du réseau de neurones convolutifs (CNN)

Le modèle utilisé est un réseau de neurones convolutifs séquentiel conçu pour extraire progressivement des caractéristiques hiérarchiques à partir des images IRM.

Les CNN sont particulièrement adaptés aux données visuelles car ils exploitent la structure spatiale des pixels et réduisent significativement le nombre de paramètres par rapport aux réseaux fully connected classiques.

Bloc convolutionnel 1

Le premier bloc contient une couche Conv2D avec 32 filtres de taille 3×3 suivie d'une activation ReLU et d'un MaxPooling 2×2.

Cette première étape permet l'extraction de caractéristiques basiques telles que les contours, les bords et les variations d'intensité. Ces éléments constituent les primitives visuelles fondamentales des images médicales.

Le choix de 32 filtres s'explique par le fait que les premières couches doivent capturer des informations simples et générales sans surcharger le modèle.

Bloc convolutionnel 2

Le deuxième bloc contient une couche Conv2D avec 64 filtres suivie d'un MaxPooling.

Cette couche combine les caractéristiques extraites précédemment afin de détecter des motifs plus complexes tels que les structures anatomiques du cerveau et les textures internes des tissus.

L'augmentation du nombre de filtres permet d'augmenter la capacité du réseau à représenter des caractéristiques plus abstraites.

Bloc convolutionnel 3

Le troisième bloc contient une couche Conv2D avec 128 filtres suivie d'un MaxPooling.

Cette étape permet l'extraction de représentations de haut niveau, correspondant à des structures globales du cerveau et à des patterns susceptibles d'indiquer la présence d'une tumeur.

L’augmentation progressive du nombre de filtres suit une logique hiérarchique : plus on avance dans le réseau, plus les représentations deviennent abstraites et complexes.

Flatten

La couche Flatten transforme les cartes de caractéristiques bidimensionnelles en un vecteur unidimensionnel. Cette transformation est nécessaire pour connecter les couches convolutionnelles aux couches entièrement connectées.

Couche entièrement connectée

Une couche Dense de 128 neurones avec activation ReLU est utilisée pour combiner les caractéristiques extraites et apprendre des relations non linéaires entre elles.

Cette couche agit comme un module de décision, capable de synthétiser les informations issues des différentes couches convolutionnelles.

Dropout

Un taux de dropout de 0.5 est appliqué afin de désactiver aléatoirement 50% des neurones pendant l’entraînement.

Cette technique permet de réduire le surapprentissage en empêchant le modèle de dépendre excessivement de certaines connexions spécifiques.

Couche de sortie

La couche finale est une couche Dense à un neurone avec activation sigmoïde. Elle produit une probabilité comprise entre 0 et 1 permettant de classifier l’image en Tumor ou No Tumor.

4.2 Architecture Neuronale (CNN)

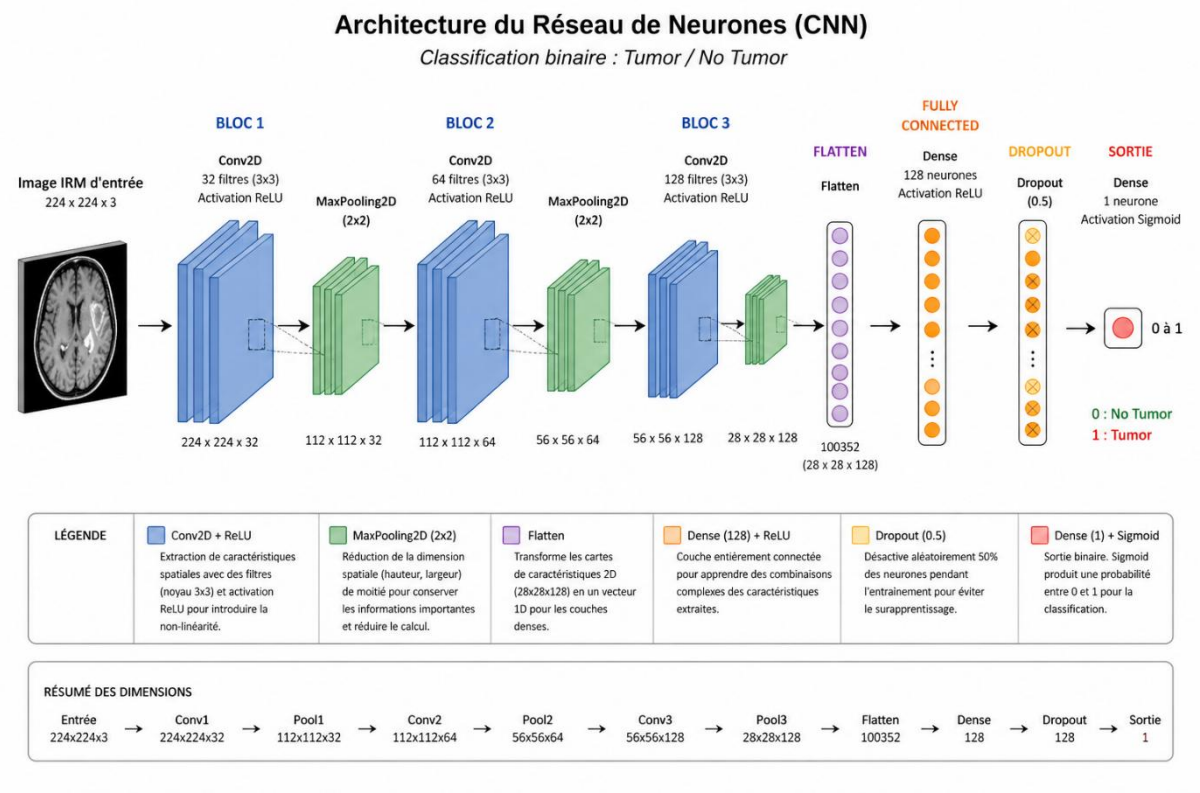

4.3 Compilation et entraînement

Le modèle est compilé avec :

- Optimiseur : Adam
- Fonction de perte : binary crossentropy
- Métrique : accuracy

L'optimiseur Adam est choisi pour sa capacité à adapter dynamiquement le taux d'apprentissage et à accélérer la convergence.

L'entraînement est réalisé sur 10 epochs avec un batch size de 32.

---

5. Résultats et analyse

Les résultats obtenus montrent une performance globale satisfaisante :

- Accuracy sur entraînement : environ 94%
- Accuracy sur validation : environ 91%

La courbe d'apprentissage montre une convergence stable de la fonction de perte, indiquant que le modèle apprend efficacement les caractéristiques discriminantes des images IRM.

L'écart modéré entre l'entraînement et la validation suggère un léger surapprentissage mais une bonne capacité de généralisation.

---

6. Discussion

Les résultats démontrent que les réseaux de neurones convolutifs sont particulièrement efficaces pour les tâches de classification d'images médicales.

Le principal avantage de cette approche réside dans la capacité du modèle à apprendre automatiquement des représentations hiérarchiques sans intervention humaine.

Cependant, le modèle reste une approche de type "boîte noire", ce qui limite son interprétabilité dans un contexte médical où l'explicabilité est essentielle.

---

7. Limites du projet

Plusieurs limites peuvent être identifiées :

- Taille et diversité du dataset limitées
- Absence d'informations spatiales précises sur les tumeurs
- Architecture CNN relativement simple comparée aux modèles récents
- Absence d'interprétabilité médicale (localisation des zones d'intérêt)

---

8. Perspectives futures

Les améliorations futures de ce projet peuvent inclure plusieurs axes.

L'utilisation d'architectures plus avancées telles que ResNet, EfficientNet ou Vision Transformers permettrait d'améliorer la performance et la robustesse du modèle.

Une augmentation plus importante et plus diversifiée du dataset permettrait également de réduire les biais et d'améliorer la généralisation.

Une évolution majeure consisterait à passer d'une tâche de classification binaire à une tâche de segmentation d'images. Cela permettrait la localisation précise des tumeurs cérébrales dans les IRM, transformant le système en un véritable outil d'aide au diagnostic.

Enfin, l'intégration de techniques d'explicabilité (Grad-CAM, attention maps) permettrait de rendre le modèle plus transparent et exploitable en contexte médical.

Conclusion

Ce projet démontre l'efficacité des réseaux de neurones convolutifs pour la classification d'images IRM cérébrales. L'architecture proposée permet une extraction hiérarchique des caractéristiques allant des motifs simples aux représentations complexes.

Les résultats obtenus sont encourageants et confirment le potentiel du deep learning dans le domaine de l'imagerie médicale. Les perspectives futures orientées vers la segmentation et la localisation des tumeurs représentent une étape essentielle vers des systèmes d'aide au diagnostic plus avancés et cliniquement exploitables.